PerfilLab

Instagram con cookies y Playwright. Big Five local y Ley de Benford.

Actualización del programa Python para extraer información visible mediante un navegador y analizarla en el equipo. La versión entregada no requiere claves API ni envía textos a Gemini u otros servicios de inferencia.

Verificación	Resultado
126 pruebas automatizadas	Aprobadas. Sin fallos, errores ni pruebas omitidas en la ejecución final.
Interfaz de escritorio	Revisada visualmente: dos opciones, tablas, tooltip y tres gráficos.
Extracción real de Instagram	**Pendiente.** No se dispuso de cookies reales configuradas; no se afirma éxito en producción.

Qué incluye la entrega

Componente	Comportamiento
Navegación	Dos opciones principales: Personalidad (Big Five) y Ley de Benford.
Sesión y extracción	Cookies propias, Chromium, lectura de perfil y contenidos visibles, listas y perfiles relacionados.
Procesamiento local	Indicadores léxicos Big Five; primer dígito, chi-cuadrado, p-valor y etiqueta de ajuste con controles de calidad.
Resultados	JSON, CSV, medios disponibles, estados explícitos y conservación de datos parciales.

Alcance científico

Big Five es aquí un indicador de vocabulario definido por el proyecto, no una prueba psicométrica validada. El ajuste a Benford describe una distribución de dígitos; no demuestra que una cuenta sea orgánica, falsa o fraudulenta.

Dos análisis en una sola aplicación

La interfaz Tkinter separa las tareas en dos pestañas. Las operaciones del navegador se ejecutan en un hilo de trabajo, mientras la ventana recibe eventos para actualizar el progreso y mostrar resultados.

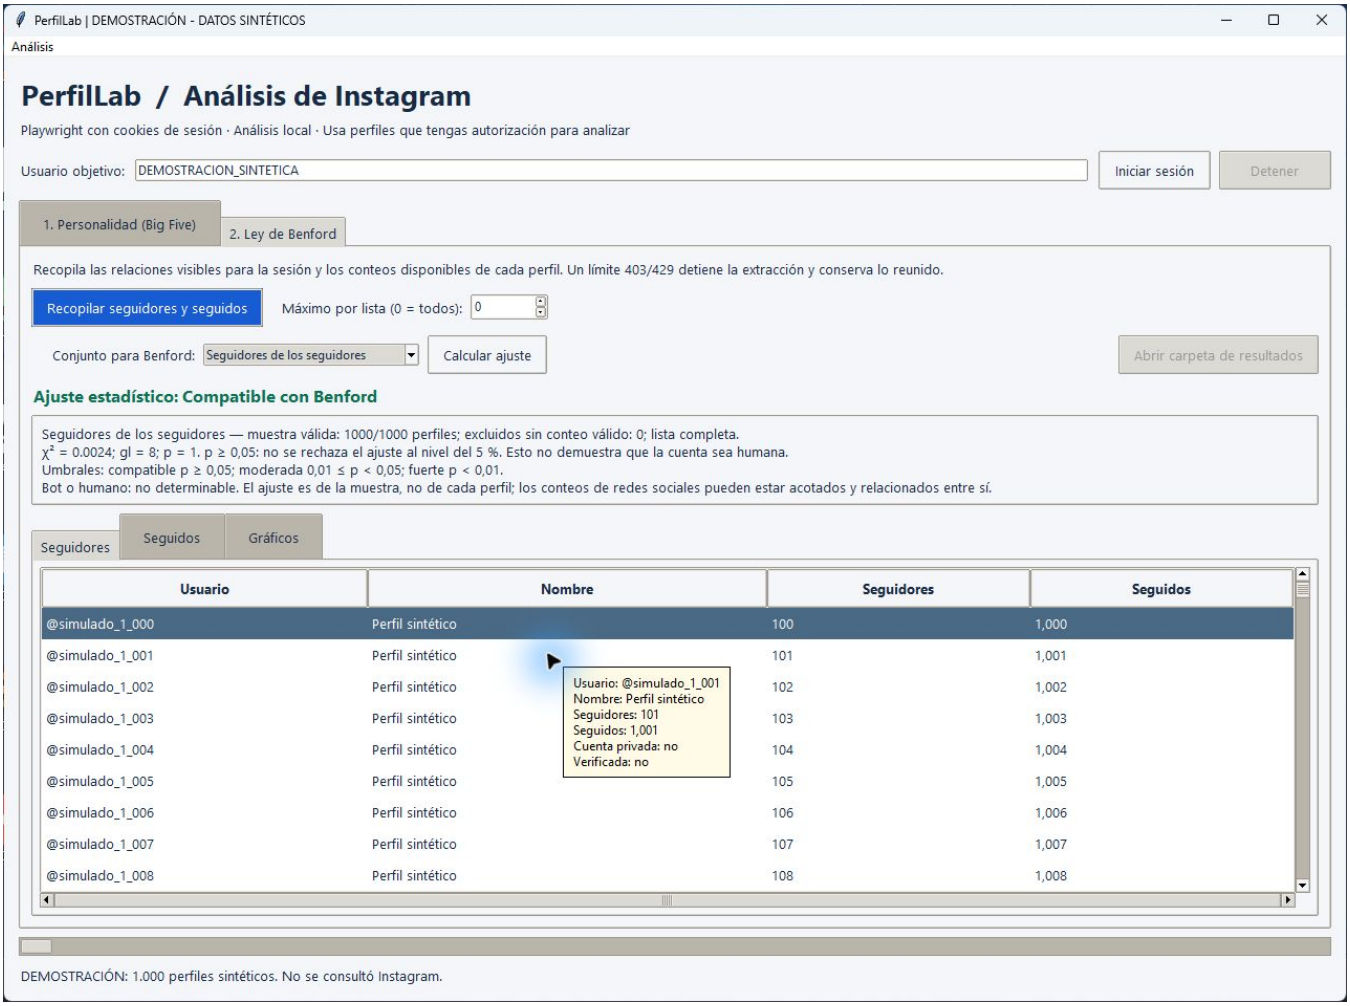


Figura 1. Captura de la aplicación funcionando en modo demostración. Las 1.000 filas son sintéticas. El tooltip muestra el usuario, sus dos conteos y las banderas del perfil.

Acción	Resultado visible
Iniciar sesión	Abre el navegador para que el usuario introduzca sus credenciales y complete la verificación.
Detener	Cancela entre acciones y conserva los datos obtenidos. Una acción en curso puede esperar su timeout.
Calcular ajuste	Cambia entre seguidores de seguidores y seguidos de seguidos, actualizando el resumen y los gráficos.

Separación de extracción, análisis y presentación

Archivo	Responsabilidad
gui.py	Ventana, menú, cola de eventos, tablas, hover, progreso, cancelación y gráficos Matplotlib.
main.py	Coordina extracción, deduplicación, análisis local y exportación JSON/CSV.
instagram/browser.py	Gestiona Chromium, cookies, navegación y desplazamiento. Detecta bloqueos y persiste la espera por 429.
instagram/browser_data.py	Normaliza datos entregados al navegador; filtra autores y relaciones, y exige conteos exactos.
instagram/parsers.py / refs.py	Funciones de normalización y validación de referencias. No ejecutan el antiguo extractor HTTP.
instagram/media_download.py	Descarga los archivos de CDN recibidos, sin enviar cookies de Instagram a esos dominios.
big_five.py / benford.py	Cálculos locales independientes de la interfaz y del navegador.
config.py / demo_data.py	Configuración local y ejemplo sintético reproducible.

Recorrido de los datos

Cookies → navegador → datos visibles → normalización → análisis local → archivos e interfaz. Playwright observa el DOM y los datos que recibe la página. No hay un cliente Gemini ni llamadas programadas a la API oficial o a endpoints internos de Instagram.

Control de calidad de la extracción

Se excluyen contenidos de otros autores. Una cuenta presente en ambas listas se consulta una sola vez. Las filas detectadas solo en el DOM no se dan por relaciones confirmadas si no puede distinguirse su pertenencia a la lista; así se evita incorporar sugerencias como si fueran seguidores.

El programa no promete recuperar contenido privado, eliminado o que el sitio no entregue. Si una lista deja de cargar sin confirmar su final, el estado queda parcial. El límite de desplazamientos evita bucles indefinidos.

Indicadores explicables, sin servicios de IA

El análisis usa diccionarios propios de términos en español e inglés para apertura, responsabilidad, extraversión, amabilidad y neuroticismo. Cada dimensión contiene un polo positivo y un polo opuesto. El texto se normaliza y se cuentan coincidencias; se excluyen enlaces, menciones y hashtags.

Índice léxico = 100 × coincidencias positivas / (positivas + opuestas)

Solo se muestra un índice cuando hay al menos **100 palabras** en el conjunto, **5 coincidencias** y **3 términos distintos** para la dimensión. Si falta evidencia, el valor es nulo. Estos umbrales son decisiones del proyecto, no criterios clínicos ni baremos validados.



Figura 2. Ejemplo sintético: 120 palabras, 90 coincidencias positivas y 30 opuestas para apertura; índice 75/100. Las otras dimensiones quedan sin puntuación. Este número caracteriza el vocabulario de la muestra, no a una persona.

El diccionario no interpreta negaciones, ironía, citas ni contexto. Para una evaluación psicológica formal se necesitaría un instrumento validado y un procedimiento distinto.

Del conteo individual a la distribución de dígitos

Se ofrecen dos conjuntos: número de seguidores de cada seguidor y número de seguidos de cada cuenta seguida. Se toma el primer dígito significativo de cada conteo positivo. Los valores ausentes, cero, negativos o abreviados (por ejemplo, 1.2K) se excluyen.

P(d) = log10(1 + 1/d), d = 1,…,9
E(d) = n × P(d)
χ^2 = Σ (O(d) − E(d))² / E(d); grados de libertad = 9 − 1 = 8

El p-valor se calcula como la cola superior de chi-cuadrado con 8 grados de libertad. Se muestra alfa = 0,05. Cuando alguna frecuencia esperada es menor que 5, la interfaz advierte sobre la aproximación. No rechazar el ajuste no equivale a demostrar que los datos siguen Benford.

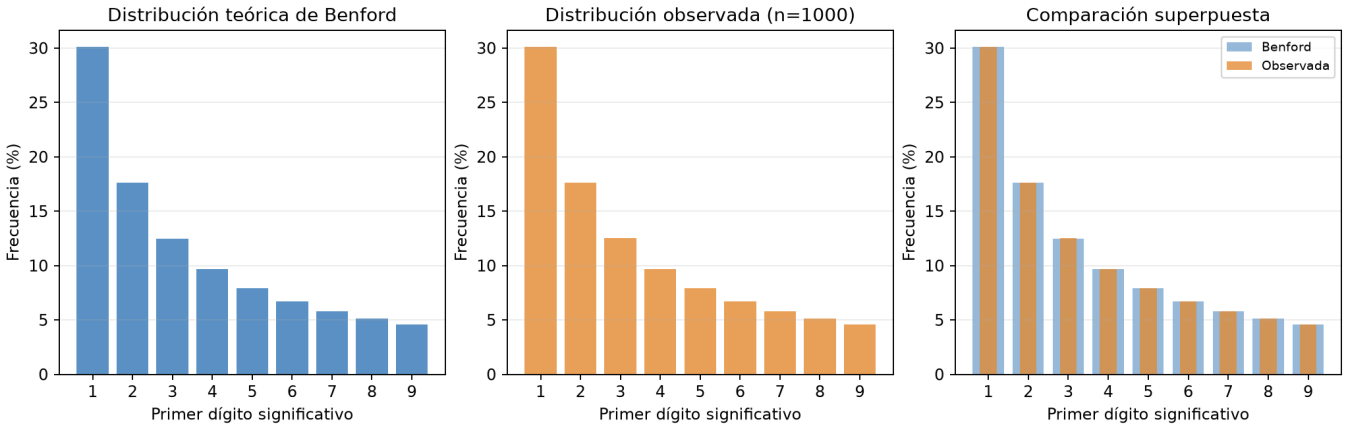


Figura 3. Los tres gráficos generados por la aplicación para la muestra sintética de 1.000 registros. Se muestra teoría, observación y superposición.

Dígito	Observado	Esperado
1	301	301.03
2	176	176.09
3	125	124.94
9	46	45.76

Comprobación numérica de la demostración: n = 1.000; χ^2 = 0.002362; gl = 8; p ≈ 1.000000. La coincidencia es intencional: los datos fueron construidos para probar el cálculo.

Los límites de las redes sociales y la dependencia entre perfiles pueden invalidar la interpretación estándar. No se clasifica a una cuenta como orgánica o anómala únicamente por este resultado.

Tres niveles de ajuste, sin inferir bot o humano

La nueva etiqueta describe la muestra del conjunto seleccionado. Se guarda en el JSON, junto con sus umbrales, el motivo y la limitación de interpretación. La interfaz utiliza el mismo cálculo que el exportador para evitar resultados distintos.

Etiqueta	Regla sin redondear	Referencia con 8 gl
Compatible con Benford	$p \geq 0{,}05$	$\chi^2 \leq 15{,}507$ aprox.
Desviación estadística moderada	$0{,}01 \leq p < 0{,}05$	$15{,}507 < \chi^2 \leq 20{,}090$ aprox.
Desviación estadística fuerte	$p < 0{,}01$	$\chi^2 > 20{,}090$ aprox.

Los valores críticos corresponden a niveles de significación del 5 % y 1 % en la tabla de NIST. La decisión usa el p-valor completo, no el chi-cuadrado redondeado. Los nombres moderada y fuerte son convenciones de presentación, no una medida del tamaño del efecto ni categorías de automatización.

Cuándo aparece No clasificable

- No hay conteos positivos válidos.
- La lista no está completa o se interrumpieron las consultas de métricas.
- Faltan métricas del conjunto seleccionado.
- Alguna frecuencia esperada es menor que 5: con nueve dígitos se necesitan al menos 110 conteos positivos para este criterio.

En estos casos se pueden mostrar el estadístico y los gráficos con el motivo de la limitación, pero no se asigna una etiqueta de ajuste. Los ceros conocidos se excluyen de Benford sin confundirlos con datos ausentes.

Por qué no se usan las etiquetas bot, casi bot y humano

Chi-cuadrado contrasta una distribución de dígitos con un modelo teórico. No observa si una cuenta está automatizada. Una muestra humana puede apartarse de Benford y una muestra automatizada puede ajustarse a él. El p-valor tampoco es una probabilidad de ser bot.

El programa muestra explícitamente **Bot o humano: no determinable**. Para desarrollar un clasificador de automatización se necesitarían otras señales de actividad, etiquetas fiables y una evaluación independiente con métricas de error.

Referencia: NIST: valores críticos de chi-cuadrado, fila de 8 grados de libertad.

126 pruebas aprobadas y revisión visual

La ejecución final usa Python 3.12 en Windows. Se ejecutó pytest con las pruebas de Chromium y Tkinter habilitadas. El archivo JUnit adjunto conserva nombres y resultados de los casos; la comprobación de dependencias no encontró incompatibilidades.

Grupo	Casos	Cobertura
Parsificación existente	64	Referencias, perfiles, publicaciones, medios y entradas inválidas con fixtures locales.
Cálculos y flujos	42	Benford, diccionarios, evidencia insuficiente, cookies, 401/403/429, cancelación, duplicados y archivos parciales.
Etiquetas de ajuste	16	Tres distribuciones, fronteras p=0,05 y p=0,01, mínimo de muestra, extracción incompleta y coincidencia entre cálculo y JSON.
Chromium real	3	Navegación, publicaciones/reels, diálogos de relaciones, métricas y detención ante 429; todas las respuestas interceptadas.
Tkinter	1	Dos pestañas, 1.000 filas por lista, detalles, dos conjuntos, tres gráficos y estados de botones.

Pruebas especialmente relevantes

- Una respuesta 429 con el texto “Please wait…” se trata como límite de solicitudes.
- La pausa persiste al reiniciar y no se abren nuevas consultas durante ella.
- Un bloqueo antes de recibir filas produce estado failed, no un mensaje de extracción exitosa.
- Una cuenta compartida entre seguidores y seguidos se visita una sola vez.
- Un conteo de cero se conserva como dato, pero se excluye del primer dígito.
- Los contenidos recomendados de otros autores no se usan en Big Five.

Revisión visual efectuada

Se abrió el modo demostración, se revisaron ambas secciones, se comprobó el cuadro flotante sobre una fila y se inspeccionaron los tres gráficos dentro de la ventana. Las capturas del informe proceden de esa revisión.

Qué no prueba esta verificación

No hubo extracción real autenticada. Las pruebas de Chromium usan páginas sintéticas y no envían tráfico a Instagram. Tampoco se ha validado psicológicamente el diccionario Big Five. El funcionamiento con Instagram real depende del formato de su página, la sesión y sus restricciones.

Instalación y prueba real responsable

Después de descomprimir el ZIP, abre PowerShell en esa carpeta. Se requiere Python con Tkinter. Crea el entorno en el equipo de destino; no copies un entorno de otro ordenador.

```
py -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
.\.venv\Scripts\python.exe -m playwright install chromium
.\.venv\Scripts\python.exe gui.py
```

Para revisar la demostración sin cookies:

```
.\.venv\Scripts\python.exe gui.py --demo
```

Para una extracción real

1. Usa **Iniciar sesión** o configura INSTAGRAM_COOKIES en tu .env local.
2. Comprueba que esa misma sesión pueda ver el perfil y sus listas.
3. Empieza con un perfil autorizado pequeño y un límite reducido.
4. Revisa el estado, las filas obtenidas y los errores antes de interpretar los gráficos.
5. Si aparece 429, respeta la espera. Playwright no elimina un bloqueo del servidor.

La sesión guardada en .auth/instagram.json tiene prioridad sobre .env. Los archivos .env, .auth/, entornos y resultados personales se excluyen del paquete. La contraseña se introduce en el navegador y no se pide desde el programa.

Archivos de la entrega

Código y dependencias, README con instrucciones, tests y fixtures, este informe y evidencia QA de datos sintéticos. El JSON de Benford incluye las estadísticas de ambos conjuntos; el informe Big Five incluye método, coincidencias y limitaciones.

Referencias técnicas

Playwright - autenticación y estado de sesión

Playwright - datos y respuestas del navegador

NIST - definición de la Ley de Benford

NIST - chi-cuadrado de bondad de ajuste

NIST - valores críticos de chi-cuadrado

MDN - código HTTP 429

El método léxico Big Five es propio del proyecto y no se atribuye a una escala psicológica validada.